



2024-2025 Bahar Yarıyılı İSTATİSTİK BÖLÜMÜ

Panel Veri Tabanlı Makine Öğrenmesi Yaklaşımı ile Çatışma Riski Tahmini: Ekonomik ve Siyasal Belirleyiciler Üzerine Bir Uygulama

Ecenur KIRAY 20023069

Danışman: Prof. Dr. Ali Hakan BÜYÜKLÜ

ÖZET

Bu çalışma, 1989–2020 yılları arasında 20 ülkeye ait panel veriler kullanılarak, makine öğrenmesi algoritmaları ile çatışma riski tahmini yapmayı amaçlamaktadır. UCDP çatışma verisi, Polity IV rejim tipi, COW-NMC askeri kapasite göstergeleri ve IMF-Dünya Bankası ekonomik verileri birleştirilmiştir. Veri ön işleme, eksik değer giderimi, normalizasyon ve SMOTE ile sınıf dengesi sağlandıktan sonra; Naive Bayes, Lojistik Regresyon, Random Forest ve XGBoost modelleri uygulanmıştır. Random Forest ve XGBoost modelleri yüksek doğruluk oranı ile öne çıkmıştır. Bu çalışma, karar vericilere erken uyarı sistemleri için katkı sunmayı hedeflemektedir.

VERİ

Bu çalışmada, 1989–2020 yılları arasında 20 ülkeye ait panel veriler kullanılmıştır. Veri setleri UCDP (çatışma bilgisi), Polity IV (rejim tipi), COW-NMC (askeri kapasite), IMF ve Dünya Bankası (ekonomik göstergeler) kaynaklıdır.

Kaynak	Açıklama
UCDP	Devletlerarası çatışma verisi
Polity IV	Rejim tipi ve rejim değişimi verisi
COW-NMC	Askeri kapasite: milper, milex, cinc
IMF/WB	Enflasyon ve askeri harcama/GSYH oranı

Veri ön işleme aşamalarında:


- Eksik değerler sütun ortalamalarıyla doldurulmuş, Değişkenler StandardScaler yöntemiyle normalize edilmiş, Sınıf dengesizliği SMOTE yöntemiyle giderilmiştir.
- Bağımlı değişken olarak ülke-yıl bazında çatışma varlığı (0: yok, 1: var) kullanılmıştır.
- Bağımsız değişkenler: milex, milper, inflation, mil_gdp, cinc, polity2, change

	country_code	year	milex	milper	cinc	inflation	mil_gdp	polity2	change	conflict
0	USA	1950	14559000	1460	0.284443	0.000059	0.000382	9.0	1.579906	0
1	USA	1951	33398000	3249	0.319499	0.000059	0.000382	9.0	1.579906	0
2	USA	1952	47852000	3636	0.311367	0.000059	0.000382	9.0	1.579906	0
3	USA	1953	49621000	3555	0.311158	0.000059	0.000382	9.0	1.579906	0
4	USA	1954	42786000	3302	0.280940	0.000059	0.000382	9.0	1.579906	0

- Veri setinde sınıflar arasında ciddi bir dengesizlik gözlenmiştir.
- Ülkelerin yaklaşık %80'inde çatışma yaşanırken, %20'sinde yaşanmamıştır. Bu durum, modelleme sürecinde **SMOTE** yöntemiyle dengelenmiştir.

Sınıf Durumu	Oran (%)
Çatışma Var (1)	%80.1
Çatışma Yok (0)	%19.9

Değişkenler Arası Korelasyon Matrisi



- milex ile milper: 0.52 → Daha fazla bütçe, daha fazla askerle birlikte.
- milper ile cinc: 0.47 → Asker sayısı arttıkça ülke gücü de artıyor.
- cinc ile milex: 0.29 → Maddi güç ve askeri harcama ilişkili.

Korelasyon analizine göre, çatışma riski en çok askeri personel (milper), askeri harcama (milex) ve ulusal güç (cinc) ile pozitif yönde ilişkilidir. Buna karşın ekonomik göstergeler (örneğin inflation, mil_gdp) doğrudan ilişki göstermemektedir. Siyasal rejim tipi (polity2) ile ilişki zayıftır.

YÖNTEM

- Modelleme sürecinde dört sınıflandırma algoritması kullanılmıştır: **Naive Bayes, Lojistik Regresyon, Random Forest ve XGBoost**.
- Analizler Python programlama dili kullanılarak Jupyter Notebook ortamında gerçekleştirilmiştir. Değerlendirme için **Accuracy, F1-Score** ve **AUC** gibi performans metrikleri kullanılmıştır.

SMOTE uygulanmadan önceki durum:

- Veri seti dengesizdir; yani bazı sınıflar çok fazla örneğe sahipken, bazı sınıflar oldukça azdır.
- Tüm modellerin hatırlama (recall) ve F1-skorları oldukça yüksek ve birbirine eşit çıkmış.
- Bu, modellerin ağırlıklı olarak çoğunluk sınıfına odaklanarak azınlık sınıfı doğru tahmin etme konusunda fazla çaba harcamadığını gösteriyor.


Model	Precision	Recall	F1-Score
Naive Bayes	0.794	1.0	0.885173
Lojistik Regresyon	0.794	1.0	0.885173
Random Forest	0.794	1.0	0.885173
XGBoost	0.794	1.0	0.885173

SMOTE uygulandıktan sonra

- SMOTE ile veri dengelenmiş, yani azınlık sınıftan da yeterli miktarda örnek oluşturularak sınıflar arasındaki fark azaltılmış.
- Dengeli veri setinde modellerin hatırlama oranları düşmüş ve artık birbirinden farklı performans göstermeye başlamışlar.
- Bazı modeller yeni veri dağılımına uyum sağlayarak daha iyi sonuçlar verirken, bazıları performans kaybı yaşamış.

Model	Precision (Çatışma)	Recall (Çatışma)	F1-Score (Çatışma)
Naive Bayes	0.636499	0.540302	0.584469
Lojistik Regresyon	0.515072	0.494962	0.504817
Random Forest	0.641994	0.535264	0.583791
XGBoost	0.637131	0.570529	0.601993

Özetle, ilk grafikte model sınıflar arasındaki dengesizliğe uyum sağlamış gibi görünüyordu ve bu yüzden performans çok yüksek çıkıyor. Ancak ikinci grafik, dengeli veri setinin gerçekte daha zorlu bir sınıflandırma problemi sunduğunu ve model performanslarında farklılaşmalara neden olduğunu gösteriyor.



Temel Çıkarımlar

- XGBoost (AUC = 0.68) en iyi performansı gösteriyor; bu model sınıflar arasında en iyi ayrımı yapabiliyor.
- Random Forest (AUC = 0.67) rekabetçi bir performans gösteriyor ve oldukça başarılı.
- Naive Bayes (AUC = 0.65) fena değil ama önceki iki modele kıyasla bir miktar daha düşük kalıyor.
- Lojistik Regresyon (AUC = 0.52) zayıf bir performans sergiliyor, yani sınıfları iyi ayırmıyor.

SONUÇ

SMOTE uygulaması, sınıf dengesizliğini azaltarak modellerin azınlık sınıfı daha iyi öğrenmesini sağlamıştır. SMOTE sonrası bazı modellerde performans düşüşü gözlenmiş, bu da dengesiz veri setlerinin yanıltıcı biçimde yüksek doğruluk verebildiğini göstermiştir.

Sonuç olarak, XGBoost ve Random Forest modelleri, çatışma riski tahmininde karar vericiler için **erken uyarı sistemleri** geliştirme potansiyeline sahiptir.

KAYNAKÇA

- [1] Cederman, L. E., Gleditsch, K. S., & Buhaug, H. (2013). *Inequality, grievances, and civil war*. Cambridge University Press.
- [2] Chadeaux, T. (2014). Early warning signals for war in the news. *Journal of Peace Research*, 51(1), 5-18.
- [3] Collier, P., & Hoeffler, A. (2004). Greed and grievance in civil war. *Oxford Economic Papers*, 56(4), 563-595